

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



CÔNG NGHỆ DỮ LIỆU LỚN
MÃ MÔN HỌC: IE212.F22.LT.CNTT

ĐỀ TÀI

HỆ THỐNG KHUYẾN NGHỊ CHO
SỰ HÀI LÒNG CỦA THÀNH VIÊN
DÀI HẠN TẠI NETFLIX

BÁO CÁO ĐỒ ÁN MÔN CÔNG NGHỆ DỮ LIỆU LỚN

Danh sách sinh viên

STT	Họ và tên	MSSV
1	Nguyễn Hoàng Phước	25210169
2	Nguyễn Hoàng Tân	25210188
3	Lê Thị Bích Tuyền	25210236
4	Nguyễn Lê Thành Đạt	25410029

Giảng viên hướng dẫn: TS. Hà Minh Tân

1. GIỚI THIỆU

Nhóm xây dựng một quy trình gợi ý phim cho người dùng có lịch sử chấm điểm kéo dài. Netflix là bối cảnh của bài toán; dữ liệu thử nghiệm là MovieLens 25M do GroupLens công bố. Đây không phải dữ liệu vận hành của Netflix.

Từ các lượt chấm trước đó, hệ thống tạo danh sách phim cho từng người dùng. Nhóm chia dữ liệu theo thời gian để đánh giá gợi ý bằng những lượt chấm về sau và so sánh ba cách xếp hạng.

1.1. Mục tiêu và phạm vi

- Sắp xếp dữ liệu theo bốn tầng RAW, BRONZE, SILVER và GOLD; cấu hình full lưu trên HDFS.
- Chia lượt chấm theo thời gian và loại phim người dùng đã chấm khỏi danh sách ứng viên.
- So sánh phim phổ biến, Spark ALS và Spark ALS kết hợp TensorFlow MLP bằng các chỉ số ngoại tuyến.
- Dùng dashboard để xem nguồn dữ liệu, trạng thái xử lý, chỉ số và danh sách gợi ý.

1.2. Quy ước dùng trong thực nghiệm

Khái niệm	Điều kiện ở cấu hình full	Giới hạn
Người dùng dài hạn	$\text{activity_span_days} \geq 180$ và $\text{rating_count} \geq 20$	Xác định từ lịch sử chấm điểm; MovieLens không có thời gian thuê bao.
Phản hồi tích cực	$\text{rating} \geq 4.0$	Điểm từ 4 sao không thay cho khảo sát hài lòng hay dữ liệu xem phim.
Cấu hình smoke	$\text{activity_span} \geq 30$ ngày và ≥ 5 ratings	Ngưỡng thấp hơn chỉ để kiểm tra với dữ liệu mẫu; cấu hình full không đổi.

Bảng 1. Quy ước chọn người dùng và đánh giá gợi ý

2. DỮ LIỆU VÀ MÔ HÌNH

2.1. MovieLens 25M

Theo tài liệu GroupLens, MovieLens 25M có 25.000.095 lượt chấm, 1.093.360 lượt gắn nhãn, 62.423 phim và 162.541 người dùng ẩn danh. Các lượt chấm được ghi nhận từ ngày 09/01/1995 đến 21/11/2019. Bộ dữ liệu được phát hành trong sáu tệp CSV.

Tệp	Nội dung chính
ratings.csv	userId, movieId, rating, timestamp
movies.csv	movieId, title, genres
tags.csv	userId, movieId, tag, timestamp
links.csv	movieId, imdbId, tmdbId
genome-scores.csv	movieId, tagId, relevance
genome-tags.csv	tagId, tag

Bảng 2. Sáu tệp dữ liệu đầu vào theo hợp đồng dữ liệu của dự án

Máy hiện chưa có tệp ml-25m.zip hay đủ sáu tệp CSV của MovieLens 25M. Các con số trên lấy từ tài liệu GroupLens, không phải số đếm của một lần chạy full tại máy này.

2.2. Cách tạo và xếp hạng phim gợi ý

Cách gợi ý phim phổ biến lấy thống kê từ tập huấn luyện làm mốc so sánh. Ở cấu hình full, Spark ALS học từ ma trận chấm điểm và tạo tối đa 100 phim ứng viên cho mỗi người dùng (cấu hình smoke của pipeline: 20). TensorFlow MLP được thiết kế để xếp hạng lại các ứng viên bằng điểm ALS, Tag Genome, thể loại, năm phát hành và lịch sử chấm điểm.

Thành phần	Cấu hình full	Vai trò
Spark ALS	rank 64; regParam 0.1; maxIter 10	Tạo phim ứng viên từ lịch sử chấm điểm
Tag Genome	topK 64	Mức liên quan giữa nhân và phim
TensorFlow MLP	tối đa 2.000.000 dòng; batch 4096; 10 epochs	Xếp hạng lại phim ứng viên
Phân vùng Spark	200 partitions	Số phần dữ liệu xử lý song song

Bảng 3. Tham số trong configs/full.yaml

Dự án tính RMSE cho cách gợi ý phim phổ biến và ALS khi dự đoán số sao. Precision, Recall, MAP, NDCG, HitRate, coverage và SatisfiedHitRate đánh giá danh sách gợi ý trên các lượt chấm về sau. Đây là chỉ số ngoại tuyến, không đo trực tiếp mức hài lòng của người dùng Netflix.

3. QUY TRÌNH DỮ LIỆU VÀ DASHBOARD

3.1. Các tầng dữ liệu

Tầng	Nội dung và xử lý
RAW	CSV MovieLens nguyên bản và tệp kiểm tra đầu vào.
BRONZE	Chuẩn hóa kiểu cột và thời điểm; tách các bản ghi lỗi.
SILVER	Dữ liệu đã kiểm tra, thống kê người dùng và ba tập chia theo thời gian.
GOLD	Đặc trưng từ tập huấn luyện, phim ứng viên và kết quả gợi ý.

Bảng 4. Vai trò của bốn tầng dữ liệu

Các thống kê về phim và người dùng được tính từ tập huấn luyện. Validation dùng để huấn luyện và điều chỉnh bộ xếp hạng lại; test chỉ dùng để đánh giá. Việc chia theo thời gian giúp tránh đưa thông tin tương lai vào mô hình.

3.2. Dashboard

Dashboard dùng HTML, CSS và JavaScript để trình bày dữ liệu, kết quả mô hình và danh sách gợi ý. Các API GET cho phép xem trạng thái, người dùng, phim, chỉ số và chất lượng dữ liệu. Khi có đủ tệp của lần chạy full, dashboard đọc kết quả đó; nếu thiếu, trang dùng dữ liệu mẫu smoke. Hai nguồn không bị trộn chỉ số.

Bản demo smoke trên dashboard chạy bằng Python/NumPy với ALS cục bộ và bộ xếp hạng logistic. Nó giúp thử giao diện và luồng dữ liệu, nhưng không phải kết quả của Spark ALS hay TensorFlow MLP.

4. CÁCH CHẠY VÀ KIỂM CHỨNG

4.1. Quy trình dự kiến cho cấu hình full

Các script lần lượt đưa dữ liệu vào RAW, tạo BRONZE, SILVER và GOLD, huấn luyện ALS, tạo phim ứng viên, huấn luyện bộ xếp hạng lại rồi đánh giá. Cấu hình full cần MovieLens 25M cùng Hadoop 3.3.6, Spark 3.5.1, Java 17, Python 3.10, PySpark và TensorFlow CPU 2.15.1.

4.2. Những gì đã kiểm chứng tại máy này

Hạng mục	Quan sát được	Trạng thái
Source và cấu hình	README, scripts, configs/full.yaml và smoke.yaml, schema contracts	Có trong dự án
Dữ liệu full	Chưa có đủ dữ liệu	Chưa sẵn sàng
Chưa có môi trường chạy full	Thiếu Hadoop/HDFS, Spark, Java và Python packages PySpark/TensorFlow	Chưa xác nhận lần chạy full
Warehouse/model full	Chưa có bảng và mô hình full	Chưa có bằng chứng
Kết quả smoke cục bộ	Có web_smoke_metrics.json và top10_recommendations.csv	Tệp kết quả của dữ liệu mẫu

Bảng 5. Trạng thái các thành phần tại thời điểm biên tập

Ngày 29/09/2026, 21 bài kiểm thử Python đã đạt. Dự án vẫn chưa có đủ dữ liệu và môi trường để xác nhận pipeline full chạy hết các bước; báo cáo không đưa ra chỉ số MovieLens 25M khi chưa chạy thật.

4.3. Cách trình bày bản demo

- Mở dashboard bằng `python -m src.web` và đọc nhãn SMOKE hoặc FULL trước khi trình bày số liệu.
- Xem lần lượt bài toán, dữ liệu, mô hình, danh sách gợi ý và cách tái lập kết quả.
- Giải thích smoke là kết quả trên dữ liệu mẫu bằng bộ xử lý cục bộ, không phải lần chạy Spark/TensorFlow.
- Chỉ công bố kết quả full sau khi có dữ liệu, môi trường và tệp đầu ra của một lần chạy thực tế.

5. KẾT QUẢ HIỆN CÓ VÀ GIỚI HẠN

5.1. Kết quả smoke trên dữ liệu mẫu

Bản lưu `artifacts/metrics/submission\_smoke\_metrics.json` tạo lúc 15:24 ngày 29/09/2026 (giờ Việt Nam) ghi 24 người dùng đủ điều kiện, 216 lượt chấm train, 24 lượt validation và 48 lượt test.

Kiểm tra thứ tự thời gian và tính duy nhất của danh sách gợi ý đều đạt. Bộ dữ liệu có 60 phim; đây chỉ là dữ liệu mẫu cục bộ.

Chỉ số của lần chạy smoke này	Phim phổ biến	ALS cục bộ	ALS + logistic
Precision@10	0,000	0,092	0,058
Recall@10	0,000	0,458	0,292
MAP@10	0,000	0,078	0,084
NDCG@10	0,000	0,189	0,142
HitRate@10	0,000	0,750	0,333
SatisfiedHitRate@10	0,000	0,750	0,333
Catalog coverage	0,283	0,717	0,433
RMSE	0,249	1,536	N/A

Bảng 6. Chỉ số từ `submission_smoke_metrics.json`, làm tròn ba chữ số thập phân

Smoke dùng ALS và logistic cục bộ, không phải Spark hay TensorFlow.

`satisfaction\_lift\_vs\_popularity` ghi 0,0 khi mốc phim phổ biến có SatisfiedHitRate@10 bằng 0; vì vậy không thể tính mức tăng tương đối. Trong bản lưu gợi ý `submission\_top10\_recommendations.csv`, điểm `rerank\_score` bằng 0,0 ở các dòng được kiểm tra; chưa thể kết luận chất lượng xếp hạng lại.

5.2. Giới hạn và việc cần làm tiếp

- Bổ sung MovieLens 25M vào `data/input` và kiểm tra mã SHA-256, số dòng của từng tệp.
- Chuẩn bị Hadoop, Spark, Java và các thư viện Python đúng phiên bản; chạy từng bước và lưu log.
- Kiểm tra đầu ra BRONZE, SILVER, GOLD, mô hình ALS/MLP và các chỉ số của lần chạy full.
- Chỉ dùng nhãn TensorFlow MLP khi đang xem kết quả full; kết quả smoke phải ghi rõ bộ xếp hạng logistic.
- Nếu có dữ liệu xem phim hoặc khảo sát, đánh giá mức hài lòng và thời gian sử dụng bằng chỉ số phù hợp hơn.

5.3. Kết luận

Dự án đã có mã nguồn, cấu hình, tài liệu dữ liệu và dashboard. Ở thời điểm báo cáo, nhóm đã kiểm chứng các bài kiểm thử Python và một lần chạy smoke trên dữ liệu mẫu. Kết quả full với MovieLens 25M còn cần môi trường Hadoop/Spark/TensorFlow và tệp đầu ra của một lần chạy thực tế.

6. TÀI LIỆU THAM KHẢO

[1] GroupLens Research. MovieLens 25M Dataset README. <https://files.grouplens.org/datasets/movielens/ml-25m-README.html> (truy cập 26/09/2026).

- [2] GroupLens Research. MovieLens 25M Dataset. <https://grouplens.org/datasets/movielens/25m/> (truy cập 26/09/2026).
- [3] Apache Spark. Collaborative Filtering. <https://spark.apache.org/docs/latest/ml-collaborative-filtering.html> (truy cập 26/09/2026).
- [4] Apache Hadoop. HDFS Architecture. <https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html> (truy cập 26/09/2026).
- [5] TensorFlow. The Sequential model. https://www.tensorflow.org/guide/keras/sequential_model (truy cập 26/09/2026).
- [6] F. Maxwell Harper and Joseph A. Konstan (2015). The MovieLens Datasets: History and Context. ACM Transactions on Interactive Intelligent Systems. <https://doi.org/10.1145/2827872>.
- [7] Nhóm 9. README, cấu hình, mã nguồn và kết quả smoke của dự án; đối chiếu ngày 29/09/2026.

7. PHÂN CÔNG NỘI DUNG THUYẾT TRÌNH

STT	Thành viên	Nội dung trình bày
1	Nguyễn Hoàng Phước	Bài toán, quy ước đánh giá và dữ liệu MovieLens.
2	Nguyễn Hoàng Tân	HDFS, các tầng dữ liệu và cách chia lịch sử theo thời gian.
3	Lê Thị Bích Tuyền	ALS tạo phim ứng viên và bộ xếp hạng lại trong cấu hình full.
4	Nguyễn Lê Thành Đạt	Dashboard, kết quả smoke, giới hạn và các bước chạy full.

Bảng 7. Phân công nội dung thuyết trình theo kịch bản nhóm



HỆ THỐNG KHUYẾN NGHỊ CHO SỰ HÀI LÒNG CỦA THÀNH VIÊN DÀI HẠN TẠI NETFLIX

CÔNG NGHỆ DỮ LIỆU LỚN · IE212.F22.LT.CNTT

Nguyễn Hoàng Phước · 25210169
Nguyễn Hoàng Tân · 25210188

Lê Thị Bích Tuyền · 25210236
Nguyễn Lê Thành Đạt · 25410029

BÀI TOÁN

DỮ LIỆU

XỬ LÝ

MÔ HÌNH

KẾT QUẢ

HỆ THỐNG CẦN LÀM GÌ?

Từ lịch sử chấm điểm đến danh sách gợi ý có thể kiểm tra.

1 · CHỌN PHIM

Tạo ứng viên chưa được người dùng chấm

2 · XẾP HẠNG

Ưu tiên phim phù hợp với từng người

3 · ĐÁNH GIÁ

Dùng các lượt chấm xảy ra sau để kiểm tra

MovieLens 25M là dữ liệu thử nghiệm, không phải dữ liệu thuê bao Netflix.



HỆ THỐNG HOẠT ĐỘNG RA SAO?


Năm phần liên tiếp từ dữ liệu đến danh sách gợi ý.





TỪ LỊCH SỬ CHẤM ĐIỂM ĐẾN TOP 10

Mỗi người dùng có một danh sách phim chưa chấm được xếp theo độ phù hợp.



Đánh giá bằng các lượt chấm xảy ra sau thời điểm huấn luyện.

BÀI TOÁN

DỮ LIỆU

XỬ LÝ

MÔ HÌNH

KẾT QUẢ

DỮ LIỆU ĐẦU VÀO

MovieLens 25M cung cấp dữ liệu để thử quy trình.

ratings.csv

userId · movieId
rating · timestamp

movies.csv

movieId · title · genres

MovieLens không có dữ liệu thuê bao, thời lượng xem hay mức hài lòng thật của Netflix.



BỐN TẦNG XỬ LÝ DỮ LIỆU

Trong cấu hình full, HDFS lưu dữ liệu và Spark xử lý các bảng.



BÀI TOÁN

DỮ LIỆU

XỬ LÝ

MÔ HÌNH

KẾT QUẢ

CHỌN NGƯỜI DỪNG VÀ CHIA THEO THỜI GIAN

Lượt chấm mới hơn chỉ dùng để điều chỉnh hoặc đánh giá.

Ngưỡng chọn người dừng

FULL: ≥ 20 lượt chấm trong ≥ 180 ngày
SMOKE: ≥ 5 lượt chấm trong ≥ 30 ngày

Lịch sử chấm điểm



Cũ hơn

Mới hơn

Đặc trưng chỉ tính từ TRAIN. Phim từ 4 sao được xem là phản hồi tích cực.

BÀI TOÁN

DỮ LIỆU

XỬ LÝ

MÔ HÌNH

KẾT QUẢ

BA CÁCH TẠO GỢI Ý

Phổ biến là móc so sánh; ALS tạo ứng viên; nhánh kết hợp xếp lại danh sách.

PHIM PHỔ BIẾN



Xếp theo số lượt chấm và điểm trung bình

ALS



Học mẫu chấm của người dùng và phim

ALS KẾT HỢP



Xếp lại ứng viên bằng đặc trưng

BÀI TOÁN

DỮ LIỆU

XỬ LÝ

MÔ HÌNH

KẾT QUẢ

FULL VÀ SMOKE LÀ HAI CẤU HÌNH

Tên mô hình giống nhau nhưng môi trường chạy và bằng chứng khác nhau.

FULL · THIẾT KẾ

MovieLens 25M
HDFS · Spark ALS
TensorFlow MLP

SMOKE · ĐÃ CHẠY

Dữ liệu mẫu
Python / NumPy ALS
Xếp hạng lại logistic

Bản nộp chỉ báo cáo metric của smoke.

DASHBOARD: GỢI Ý CHO MỘT NGƯỜI

Ảnh thật ở chế độ SMOKE: hồ sơ người dùng và ba danh sách phim.

Chọn một người dùng để xem lịch sử chấm điểm và danh sách gợi ý của từng mô hình.

Tìm mã

Chọn người dùng

MÃ NGƯỜI DÙNG

1

Người đang được chọn

LƯỢT CHẤM

12

Trong lịch sử dữ liệu

ĐIỂM TRUNG BÌNH

4.042

Trên thang 5 sao

THỜI GIAN HOẠT ĐỘNG

55

Số ngày giữa lượt đầu và lượt cuối

TRAIN / VALIDATION / TEST

9 / 1 / 2

Số lượt chấm ở mỗi phần

So sánh các phim được đề xuất cho cùng một người dùng.

Phim phổ biến

Xếp hạng theo mức độ phổ biến trong tập huấn luyện.

HẠNG	TÊN PHIM	THỂ LOẠI
#1	Night Convoy (1990)	Action, Thriller
#2	Broken Alibi (1991)	Action, Crime, Thriller
#3	Shadow Warrant (1992)	Action, Thriller
#4	River Picnic (1977)	Adventure, Children, Comedy

ALS cục bộ

Dùng điểm ALS để chọn phim ứng viên.

HẠNG	TÊN PHIM	THỂ LOẠI	ĐIỂM ALS
#1	Broken Alibi (1991)	Action, Crime, Thriller	8.2328
#2	Picnic Comet (1984)	Adventure, Animation, Children, Comedy	5.2130
#3	Razor Embassy (1990)	Action, Thriller	4.1979


ALS + logistic

Dùng mô hình logistic cục bộ để xếp hạng lại ứng viên ALS.

HẠNG	TÊN PHIM	THỂ LOẠI	ĐIỂM XẾP HẠNG LẠI
#1	River Picnic (1977)	Adventure, Children, Comedy	0.0000
#2	Clockwork Garden (1977)	Adventure, Children, Fantasy, Comedy	0.0000

KẾT QUẢ SMOKE TRÊN 24 NGƯỜI DÙNG

Precision@10 và NDCG@10 (%), bản lưu 15:24 ngày 29/09/2026.



Nguồn: artifacts/metrics/submission_smoke_metrics.json

BÀI TOÁN

DỮ LIỆU

XỬ LÝ

MÔ HÌNH

KẾT QUẢ

ĐÃ KIỂM CHỨNG GÌ?

Chỉ kết luận trong phạm vi đã chạy trên máy.

21

bài kiểm thử đạt

24

người dùng trong smoke

Còn cần chạy MovieLens 25M trên Hadoop, Spark và TensorFlow để có kết quả full.

XIN CẢM ƠN



NHÓM 9

Hệ thống đã có luồng xử lý, mô hình thử và dashboard để xem kết quả.

GVHD: TS. Hà Minh Tân